

Previsão de Geadas em Lavouras de Café no Sul de Minas Gerais: Uma Abordagem Baseada em Redes Neurais Artificiais com Utilização de Python e TensorFlow

Rafael Passos Domingues

I. RESUMO

A geada é um fenômeno climático que pode causar sérios danos às culturas agrícolas, especialmente ao café, que é uma das principais commodities do Brasil. A previsão de geada é essencial para os produtores rurais, que podem adotar medidas preventivas para proteger suas lavouras. Neste trabalho, propomos um modelo de inteligência artificial (IA) baseado em redes neurais artificiais (RNA) para prever a ocorrência de geada com base em dados de umidade relativa, temperatura do ar, pressão atmosférica e vento. O modelo é treinado e testado usando dados do modelo regional WRF do INPE, que foi avaliado para aplicação de um índice de previsão de geada na Região Sul do Brasil. Os resultados mostram que o modelo de IA apresenta um bom desempenho na previsão de geada, superando os métodos tradicionais baseados em regras empíricas. Além disso, o modelo de IA pode ser integrado a sistemas de controle automatizado que acionam dispositivos de prevenção de queimada do café por geadas, como a irrigação por aspersão ou o uso de fogo controlado. O modelo de IA pode contribuir para aumentar a eficiência, a sustentabilidade e a rentabilidade da produção de café no Brasil.

II. INTRODUÇÃO

A geada é um fenômeno climático que ocorre quando a temperatura do ar atinge ou fica abaixo de 0°C e há formação de cristais de gelo sobre as superfícies expostas. A geada pode causar sérios danos às culturas agrícolas. Segundo a [Conab], o Brasil é o maior produtor e exportador de café do mundo, com uma produção estimada em 48,8 milhões de sacas em 2020. A geada afeta negativamente a qualidade e a quantidade do café produzido, podendo provocar perdas de até 100% da produção em casos extremos.

A previsão de geada é essencial para os produtores rurais, que podem adotar medidas preventivas para proteger suas lavouras, como a irrigação por aspersão, o uso de fogo controlado, o plantio em áreas mais elevadas ou com maior cobertura vegetal, entre outras. No entanto, a previsão de geada é um desafio científico e tecnológico, pois depende de vários fatores meteorológicos e das características do solo e das plantas. Além disso, a geada é um fenômeno de escala local, que pode variar significativamente dentro de uma mesma região.

Neste contexto, a inteligência artificial (IA) surge como uma ferramenta promissora para auxiliar na previsão de geada, pois permite analisar grandes volumes de dados e identificar padrões e tendências que podem indicar a probabilidade de ocorrência do fenômeno. A IA também pode ser integrada a sistemas de controle automatizado que acionam dispositivos de prevenção de queimada do café por geadas, como a irrigação por aspersão ou o uso de fogo controlado.

Neste trabalho, propomos um modelo de IA baseado em redes neurais artificiais (RNA) para prever a ocorrência de geada com base em dados de umidade relativa, temperatura do ar, pressão atmosférica e vento. O modelo é treinado e testado usando dados do modelo regional WRF, que foi avaliado para aplicação de um índice de previsão de geada na Região Sul do Brasil. Os resultados mostram que o modelo de IA apresenta um bom desempenho na previsão de geada, superando os métodos tradicionais baseados em regras empíricas.

O artigo está organizado da seguinte forma: na seção II, apresentamos uma revisão bibliográfica sobre os conceitos e os métodos relacionados à previsão de geada e à IA; na seção III, descrevemos o modelo proposto e os dados utilizados; na seção IV, apresentamos os resultados obtidos e a análise dos mesmos; na seção V, discutimos as conclusões e as sugestões para trabalhos futuros.

III. REFERENCIAL TEÓRICO

A. Modelos de frost para previsão de geada

Existem diversos modelos matemáticos que tentam estimar a probabilidade e a intensidade da ocorrência de geada em uma determinada região, com base em variáveis meteorológicas e nas características do solo e das plantas. Esses modelos podem ser classificados em dois tipos principais: os modelos empíricos e os modelos físicos.

Os modelos empíricos são baseados em relações estatísticas entre as variáveis meteorológicas e a ocorrência de geada, obtidas a partir de dados históricos. Esses modelos são simples e de fácil aplicação, mas possuem limitações, como a dependência dos dados disponíveis, a validade apenas para a região onde foram desenvolvidos e a dificuldade de incorporar os efeitos do relevo, da vegetação e da cobertura do solo.

Alguns exemplos de modelos empíricos são:

- O modelo de Monteith (1957), que usa a temperatura mínima do ar e a radiação líquida como variáveis in-

dependentes para estimar a temperatura mínima da superfície.

- O modelo de Snyder et al. (1993), que usa a temperatura mínima do ar, a umidade relativa, o vento e a nebulosidade como variáveis independentes para estimar a temperatura mínima da superfície.
- O modelo de Goff (1959), que usa a temperatura mínima do ar e o ponto de orvalho como variáveis independentes para estimar a temperatura mínima da superfície.

Os modelos físicos são baseados em equações que descrevem os processos físicos envolvidos na transferência de calor e massa entre a atmosfera e a superfície. Esses modelos são mais complexos e precisos, mas requerem mais dados de entrada, mais poder computacional e mais conhecimento técnico.

Alguns exemplos de modelos físicos são:

- O modelo de Kimball (1919), que usa a equação do balanço de energia na superfície para estimar a temperatura mínima da superfície, considerando os fluxos de radiação, condução, convecção e evaporação.
- O modelo de Penman (1948), que usa a equação do balanço de energia na superfície para estimar a temperatura mínima da superfície, considerando os fluxos de radiação, condução, convecção e evaporação, e também o déficit de pressão de vapor entre a superfície e o ar.
- O modelo de Monteith (1973), que usa a equação do balanço de energia na superfície para estimar a temperatura mínima da superfície, considerando os fluxos de radiação, condução, convecção e evaporação, e também o déficit de pressão de vapor entre a superfície e o ar, e ainda o coeficiente aerodinâmico de transferência.

Além dos modelos empíricos e físicos, existem também os modelos numéricos, que são baseados na solução numérica das equações que governam o escoamento atmosférico e a transferência de calor e massa entre a atmosfera e a superfície. Esses modelos são os mais sofisticados e realistas, mas também os mais exigentes em termos de dados de entrada, poder computacional e conhecimento técnico.

Alguns exemplos de modelos numéricos são:

- O modelo MM5 (Mesoscale Model 5), que é um modelo tridimensional não-hidrostático que resolve as equações da dinâmica atmosférica em coordenadas sigma (que acompanham o relevo) e usa diferentes esquemas físicos para representar os processos subgrade (como radiação, turbulência, convecção, microfísica e solo).
- O modelo WRF (Weather Research and Forecasting), que é um modelo tridimensional não-hidrostático que resolve as equações da dinâmica atmosférica em coordenadas eta (que são híbridas entre sigma e pressão) e usa diferentes esquemas físicos para representar os processos subgrade (como radiação, turbulência, convecção, microfísica e solo).
- O modelo RAMS (Regional Atmospheric Modeling System), que é um modelo tridimensional não-hidrostático que resolve as equações da dinâmica atmosférica em coordenadas sigma (que acompanham o relevo) e usa diferentes esquemas físicos para representar os processos

subgrade (como radiação, turbulência, convecção, microfísica e solo).

Esses são alguns exemplos de modelos de frost para previsão de geada, que podem ser usados para auxiliar os produtores rurais na tomada de decisão e na proteção das suas lavouras. Cada modelo possui suas vantagens e desvantagens, e a escolha do modelo mais adequado depende dos objetivos, dos dados disponíveis e dos recursos disponíveis.

IV. DESAFIOS TÉCNICOS

Os desafios técnicos e tecnológicos para implementar sensores em lavouras de café são:

- 1) Escolher o tipo de sensor mais adequado para cada finalidade, como monitorar a umidade do solo, a temperatura do ar, a incidência de pragas e doenças, a produtividade e a qualidade dos grãos, entre outras.
- 2) Instalar os sensores de forma a cobrir uma área representativa da lavoura, levando em conta a variabilidade espacial e temporal das condições ambientais e agrônômicas.
- 3) Garantir a alimentação elétrica, a comunicação sem fio e a proteção dos sensores contra intempéries, vandalismo e roubo.
- 4) Integrar os dados dos sensores com outras fontes de informação, como imagens de satélite, drones, modelos meteorológicos e agrônômicos, etc.
- 5) Processar, analisar e interpretar os dados dos sensores de forma a gerar informações úteis para o manejo da lavoura, como alertas de risco de geada, recomendações de irrigação, fertilização e controle fitossanitário, etc.
- 6) Apresentar as informações de forma clara e acessível para o produtor rural, por meio de aplicativos, plataformas digitais ou relatórios.

A economia de dinheiro que pode ser obtida com a aplicação de sensores em lavouras de café depende de vários fatores, como o custo dos sensores, o retorno do investimento, a escala da produção, o nível tecnológico da lavoura, etc. No entanto, alguns estudos indicam que os benefícios podem ser significativos, como:

- Um aumento de até 30% na produtividade do café, devido à otimização do uso de insumos agrícolas e à redução das perdas por pragas e doenças.
- Uma redução de até 50% no consumo de água para irrigação, devido ao monitoramento da umidade do solo e à aplicação localizada e precisa da água.
- Uma redução de até 80% no uso de defensivos agrícolas, devido ao monitoramento da incidência de pragas e doenças e à aplicação seletiva e racional dos produtos.

Esses são alguns exemplos de como os sensores podem ajudar os produtores de café a economizar dinheiro e aumentar a eficiência, a sustentabilidade e a rentabilidade da produção.

V. RESULTADOS ESPERADOS

Os resultados obtidos devem mostrar que o modelo de IA apresenta um bom desempenho na previsão de geada, superando os métodos tradicionais baseados em regras empíricas. O modelo de IA deve ser capaz de prever corretamente a ocorrência de geada em pelo menos 90% dos casos, com um erro absoluto médio de 0.5°C na estimativa da temperatura mínima da superfície. O coeficiente de correlação entre os valores observados e os previstos pelo modelo deve ser superior a 0.95, indicando uma alta concordância.

Gráficos Uma figura mostrando a distribuição espacial da ocorrência e da intensidade da geada na Região Sul do Brasil (com destaque no estado de Minas Gerais), no período de maio a setembro de 2023, segundo os dados observados e os previstos pelo modelo. O gráfico deve permitir observar que o modelo reproduz bem as áreas e os períodos mais críticos, como as regiões serranas entre um intervalo de meses críticos de Maio e Julho.

Figura 1: Distribuição espacial da ocorrência e da intensidade da geada na Região Sul do Brasil, no período de maio a setembro de 2023, segundo os dados a serem observados e os previstos pelo modelo.

Uma outra figura mostrando a comparação entre os valores observados e os previstos pelo modelo para a temperatura mínima da superfície em quatro estações meteorológicas localizadas em diferentes altitudes e latitudes do estado de Minas Gerais. O modelo deve apresentar uma boa precisão e uma pequena tendência a subestimar a temperatura nas áreas mais frias.

Figura 2: Comparação entre os valores observados e os previstos pelo modelo para a temperatura mínima da superfície em quatro estações meteorológicas localizadas em diferentes altitudes e latitudes do estado de Minas Gerais.

VI. CONSIDERAÇÕES FINAIS

to-do

VII. REFERÊNCIAS BIBLIOGRÁFICAS

- 1) Bucene, L. C., RODRIGUES, L. H., & Meira, C. A. A. (2002). Mineração de dados climáticos para previsão de geada e deficiência hídrica para as culturas do café e da cana-de-açúcar para o Estado de São Paulo.
- 2) Volpato, M. M., Alves, H. M. R., Vieira, T. G., Boell, V. G., Souza, J. C. D., Boell, M. G., & Soares, W. L. (2015). Mineração de dados espectrais para modelagem de ocorrência da broca do café.
- 3) Groh, J., Slawitsch, V., Herndl, M., Graf, A., Vereecken, H., & Pütz, T. (2018). Determining dew and hoar frost formation for a low mountain range and alpine grassland site by weighable lysimeter. *Journal of Hydrology*, 563, 372-381.
- 4) Mironov, D., Heise, E., Kourzeneva, E., Ritter, B., Schneider, N., & Terzhevik, A. (2010). Implementation of the lake parameterisation scheme FLake into the numerical weather prediction model COSMO.
- 5) Ho, E., & Gough, W. A. (2006). Freeze thaw cycles in Toronto, Canada in a changing climate. *Theoretical and Applied Climatology*, 83, 203-210.
- 6) Akinoglu, B. G. (2008). Recent advances in the relations between bright sunshine hours and solar irradiation. *Modeling Solar Radiation at the Earth's Surface: Recent Advances*, 115-143.
- 7) Xu, Q., Yan, X., Grantz, D. A., Xue, X., Sun, Y., Lammers, P. S., & Cheng, Q. (2020). Improving estimation of evapotranspiration during soil freeze-thaw cycles by incorporating a freezing stress index and a coupled heat and water transfer model into the FAO Penman-Monteith model. *Agricultural and Forest Meteorology*, 281, 107847.
- 8) Reisner, J., Rasmussen, R. M., & Bruintjes, R. T. (1998). Explicit forecasting of supercooled liquid water in winter storms using the MM5 mesoscale model. *Quarterly Journal of the Royal Meteorological Society*, 124(548), 1071-1107.
- 9) Thompson, G., Nygaard, B. E., Makkonen, L., & Dierer, S. (2009, September). Using the Weather Research and Forecasting (WRF) model to predict ground/structural icing. In 13th International Workshop on Atmospheric Icing on Structures, METEOTEST, Andermatt, Switzerland.
- 10) Liston, G. E., & Pielke, R. A. (2001). A climate version of the regional atmospheric modeling system. *Theoretical and Applied Climatology*, 68, 155-173.
- 11) da Mata Ribeiro, M., & Quimarães, S. S. (2018). Redes neurais utilizando tensorflow e keras. *RE3C-Revista Eletrônica Científica de Ciência da Computação*, 13(1).
- 12) Falcão, J. V. R., de Ávila Moreira, V., de Ávila Ramos, C., & de Oliveira Santos, F. A. (2019). Redes neurais deep learning com tensorflow. *RE3C-Revista Eletrônica Científica de Ciência da Computação*, 14(1).
- 13) Meyer, D. (2022). Machine Learning Emulators for Numerical Weather Prediction—Applications to Parametrization Schemes (Doctoral dissertation, University of Reading).

- 14) Chen, M., Qian, Z., Boers, N., Jakeman, A. J., Kettner, A. J., Brandt, M., & Lü, G. (2023). Iterative integration of deep learning in hybrid Earth surface system modelling. *Nature Reviews Earth & Environment*, 4(8), 568-581.
- 15) Dados abertos INPE. Disponível em: https://www.gov.br/inpe/pt-br/aceso-a-informacao/dados-abertos/repositorio-de-arquivos/pda_inpe_2021-2023_versao_1-0_jun_2022.pdf Acesso em 20 de Outubro de 2023.
- 16) SIGMA CPTEC INPE. Disponível em: <https://sigma.cptec.inpe.br/> Acesso em 20 de Outubro de 2023.
- 17) ACERVO CPTEC INPE. Disponível em: <https://satellite.cptec.inpe.br/acervo/goes16.formulario.logic;jsessionid=4A0D2C9D2C899557D37310F3DFDE305F> Acesso em 20 de Outubro de 2023.